**Datathon FIAP – Fase 5: Previsão de Risco de Defasagem Educacional**

**Instituição de Ensino:** FIAP | POSTECH (Pós-Tech em Data Analytics)
**Organização Parceira:** Associação Passos Mágicos
**Solução em Nuvem.**

## 1. Introdução

Este projeto foi desenvolvido como entrega final do Datathon (Fase 5) da Pós-Graduação em Data Analytics da FIAP.

O objetivo principal foi analisar os dados educacionais da Associação Passos Mágicos — entidade que transforma a vida de crianças e jovens em situação de vulnerabilidade social há mais de 30 anos — e criar um **Modelo Preditivo (Inteligência Artificial)** capaz de antecipar quais alunos estão em risco de defasagem escolar, permitindo uma intervenção pedagógica preventiva.

## 2. Contexto do Negócio e Indicadores PEDE

A Passos Mágicos avalia o desenvolvimento dos seus alunos por meio da **PEDE** (Pesquisa Extensiva do Desenvolvimento Educacional). O principal indicador global é o INDE (Índice de Desenvolvimento Educacional), que combina 7 dimensões:

| Indicador | Nome Extenso | Descrição / Abrangência |
|---|---|---|
| **IAN** | Adequação de Nível | Avalia se o aluno está na série correta para a sua idade cronológica. |
| **IDA** | Aprendizagem | Nota média obtida nas disciplinas essenciais (Matemática, Português e Inglês). |
| **IEG** | Engajamento | Mede a frequência, nível de participação e pontualidade na entrega de tarefas. |
| **IAA** | Autoavaliação | Percepção e avaliação do próprio aluno sobre o seu processo de aprendizado. |

| Indicador | Nome Extenso | Descrição / Abrangência |
|---|---|---|
| **IPS** | Psicossocial | Avaliação do bem-estar emocional, convivência e ambiente familiar do aluno. |
| **IPP** | Psicopedagógico | Avaliação do desenvolvimento cognitivo e de aprendizagem realizada por especialistas. |
| **IPV** | Ponto de Virada | Mede o grau de autonomia, protagonismo e maturidade escolar desenvolvidos. |

**3. Objetivos do Projeto**

- **Análise Exploratória (EDA):** Responder às perguntas de negócio sobre a evolução das notas, engajamento e fatores emocionais ao longo das fases (Quartzo, Ágata, Ametista e Topázio).
- **Modelo de Machine Learning:** Construir uma Inteligência Artificial capaz de calcular a probabilidade de um aluno entrar em risco de defasagem escolar.
- **Aplicativo Web (Streamlit):** Disponibilizar uma ferramenta simples e intuitiva para que professores e coordenadores possam simular dados de alunos e visualizar os alertas e recomendações em tempo real.

**4. Metodologia e Machine Learning**

**4.1 Preparação dos Dados**

- **Limpeza de Dados:** Padronização de nomes, correção de idades e remoção de colunas que poderiam causar vazamento de dados (*data leakage*) para a IA.
- **Criação de Novas Informações (Feature Engineering):**
    - media_academica: Média direta das notas de Matemática, Português e Inglês.
    - media_comportamental: Média entre engajamento, autoavaliação e aspectos psicossociais.
    - delta_inde: Variação do desempenho geral do aluno em relação ao ano anterior.

**4.2 O que o modelo prevê? (Target)**

O modelo calcula o risco com base no indicador IAN:

- **Com Risco de Defasagem (Classe 1):** Alunos com IAN $\le$ 5.
- **Sem Risco de Defasagem (Classe 0):** Alunos com IAN > 5.

**4.3 Separação Temporal dos Dados (Treino vs. Teste)**

- **Dados de Treino:** Anos de 2022 e 2023 (utilizados para o aprendizado do modelo).
- **Dados de Teste:** Ano de 2024 (mantidos isolados para avaliar a capacidade preditiva em dados futuros).

**4.4 Algoritmos Testados e Escolha Final**

| Algoritmo | Descrição e Abordagem | Status de Seleção |
|---|---|---|
| **Regressão Logística** | Modelo estatístico linear tradicional e de alta interpretabilidade. | Avaliado |
| **Random Forest** | Ensemble baseado na combinação de múltiplas árvores de decisão. | **Modelo Escolhido** |
| **XGBoost** | Algoritmo de *gradient boosting* otimizado para alto desempenho. | Avaliado |
| **MLP (Rede Neural)** | Arquitetura de rede neural artificial para captura de padrões complexos. | Avaliado |

**4.5 Ajuste do Limite de Alerta (Threshold)**

O limite decisório (*threshold*) foi ajustado para **35% (0,35)**. Caso o modelo detecte uma probabilidade superior a 35% de risco de defasagem, o alerta pedagógico é emitido automaticamente para intervenção preventiva.

**5. Resultados e Principais Insights**

**Métricas do Modelo (Base Real de 2024)**

- **Acurácia Geral:** 61%
- **Sensibilidade (Recall da Classe de Risco):** 62%

- **Indicadores Mais Relevantes:** Histórico do INDE, Ponto de Virada (IPV), Desempenho Acadêmico (IDA) e Engajamento (IEG).

**Insights de Negócio**

- A média global do IAN apresentou evolução positiva, subindo de 6,42 em 2022 para 7,68 em 2024.
- O Engajamento (IEG) demonstrou correlação direta com o aumento no desempenho acadêmico (IDA).
- Oscilações negativas no indicador Psicossocial (IPS) atuam como antecedente antecedente de quedas no rendimento acadêmico, manifestando-se com 1 a 2 ciclos de antecedência.

**6. Aplicação Web Interativa (Streamlit)**

A solução está implantada e acessível EM LOCAL.

**7. Como Executar o Projeto Localmente (Windows)**

Para iniciar a aplicação em ambiente local Windows, execute o script automatizado:

1. Navegue até o diretório raiz do projeto.
2. Execute o arquivo executar_app_.bat com duplo clique.

**8. Estrutura do Repositório GitHub**

.

├── .streamlit/

│ └── config.toml

├── data/

├── models/

├── notebooks/

├── references/

├── reports/

├── .gitignore

├── LICENSE

├── README.md

├── app.py

├── executar_app_.bat

├── pyproject.toml

└── requirements.txt

**9. Desenvolvedor do Projeto**

- **Eduardo Junior de Almeida Sant Anna**

**10. Impacto Social & Licença**

Este projeto é voltado ao suporte de ações de impacto social e está licenciado sob a Licença MIT.